

La regla de aprendizaje del perceptrón

En este ejemplo, calcularemos los pesos y sesgos de un perceptrón de una única neurona, el cual funciona como una compuerta lógica AND. El perceptrón recibe dos entradas y produce una salida que corresponde a la operación AND de dichas entradas.

En cada iteración, el error se calcula como la diferencia entre la salida esperada y la salida producida por el perceptrón. Los pesos y sesgos se actualizan según la regla de aprendizaje del perceptrón:

$$\mathbf{W} = \mathbf{W} + e\mathbf{p}^T \quad \text{y} \quad b = b + e$$

Por simplicidad, asumiremos que los pesos y sesgos iniciales son: $W = [1.5 \quad 1.5]$ y $b = 1$, respectivamente.

Iteración 01

Condiciones iniciales:

$$\begin{aligned} \mathbf{p} &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} \\ \mathbf{W} &= [1.5 \quad 1.5] \\ b &= 1 \end{aligned}$$

Calculamos el error:

$$\begin{aligned} a &= \text{hardlim}(\mathbf{W}\mathbf{p} + b) = \text{hardlim}\left([1.5 \quad 1.5] \times \begin{bmatrix} 0 \\ 0 \end{bmatrix} + 1\right) = \text{hardlim}(1) = 1 \\ e &= 0 - 1 = -1 \end{aligned}$$

Ajustamos los pesos y sesgos:

$$\begin{aligned} \mathbf{W} &= \mathbf{W} + e\mathbf{p}^T = [1.5 \quad 1.5] + (-1) [0 \quad 0] = [1.5 \quad 1.5] \\ b &= 1 - 1 = 0 \end{aligned}$$

Iteración 02

Condiciones iniciales:

$$\mathbf{p} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$
$$\mathbf{W} = \begin{bmatrix} 1.5 & 1.5 \end{bmatrix}$$
$$b = 0$$

Calculamos el error:

$$a = \text{hardlim}(\mathbf{W}\mathbf{p} + b) = \text{hardlim}\left(\begin{bmatrix} 1.5 & 1.5 \end{bmatrix} \times \begin{bmatrix} 0 \\ 1 \end{bmatrix} + 0\right) = \text{hardlim}(1.5) = 1$$
$$e = 0 - 1 = -1$$

Ajustamos los pesos y sesgos:

$$\mathbf{W} = \mathbf{W} + e\mathbf{p}^T = \begin{bmatrix} 1.5 & 1.5 \end{bmatrix} + (-1) \begin{bmatrix} 0 & 1 \end{bmatrix} = \begin{bmatrix} 1.5 & 0.5 \end{bmatrix}$$
$$b = 0 - 1 = -1$$

Iteración 03

Condiciones iniciales:

$$\mathbf{p} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$
$$\mathbf{W} = \begin{bmatrix} 1.5 & 0.5 \end{bmatrix}$$
$$b = -1$$

Calculamos el error:

$$a = \text{hardlim}(\mathbf{W}\mathbf{p} + b) = \text{hardlim}\left(\begin{bmatrix} 1.5 & 0.5 \end{bmatrix} \times \begin{bmatrix} 1 \\ 0 \end{bmatrix} - 1\right) = \text{hardlim}(0.5) = 1$$
$$e = 0 - 1 = -1$$

Ajustamos los pesos y sesgos:

$$\mathbf{W} = \mathbf{W} + e\mathbf{p}^T = [1.5 \ 0.5] + (-1) [1 \ 0] = [0.5 \ 0.5]$$
$$b = -1 - 1 = -2;$$

Iteración 04

Condiciones iniciales:

$$\mathbf{p} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$
$$\mathbf{W} = [0.5 \ 0.5]$$
$$b = -2$$

Calculamos el error:

$$a = \text{hardlim}(\mathbf{W}\mathbf{p} + b) = \text{hardlim}\left([0.5 \ 0.5] \times \begin{bmatrix} 1 \\ 1 \end{bmatrix} - 2\right) = \text{hardlim}(-1) = 0$$
$$e = 1 - 0 = 1$$

Ajustamos los pesos y sesgos:

$$\mathbf{W} = \mathbf{W} + e\mathbf{p}^T = [0.5 \ 0.5] + (1) [1 \ 1] = [1.5 \ 1.5]$$
$$b = -2 + 1 = -1;$$

Iteración 05

Condiciones iniciales:

$$\mathbf{p} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$
$$\mathbf{W} = [1.5 \ 1.5]$$
$$b = -1$$

Calculamos el error:

$$a = \text{hardlim}(\mathbf{W}\mathbf{p} + b) = \text{hardlim}\left(\begin{bmatrix} 1.5 & 1.5 \end{bmatrix} \times \begin{bmatrix} 0 \\ 0 \end{bmatrix} - 1\right) = \text{hardlim}(-1) = 0$$
$$e = 0 - 0 = 0$$

Como el error es 0 para este vector de entrada, no hay cambio en los pesos y sesgos del perceptrón.

Iteración 06

Condiciones iniciales:

$$\mathbf{p} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$
$$\mathbf{W} = \begin{bmatrix} 1.5 & 1.5 \end{bmatrix}$$
$$b = -1$$

Calculamos el error:

$$a = \text{hardlim}(\mathbf{W}\mathbf{p} + b) = \text{hardlim}\left(\begin{bmatrix} 1.5 & 1.5 \end{bmatrix} \times \begin{bmatrix} 0 \\ 1 \end{bmatrix} - 1\right) = \text{hardlim}(0.5) = 1$$
$$e = 0 - 1 = -1$$

Ajustamos los pesos y sesgos:

$$\mathbf{W} = \mathbf{W} + e\mathbf{p}^T = \begin{bmatrix} 1.5 & 1.5 \end{bmatrix} + (-1) \begin{bmatrix} 0 & 1 \end{bmatrix} = \begin{bmatrix} 1.5 & 0.5 \end{bmatrix}$$
$$b = -1 - 1 = -2;$$

En este punto, el perceptrón ha aprendido a clasificar correctamente las entradas. Si gustas, puedes verificarlo calculando la salida para cada uno de los vectores de entrada.

De esta forma, el perceptrón obtenido mediante el entrenamiento se muestra a continuación:

