

Clasificador bayesiano ingenuo

Desarrollo de Aplicaciones Avanzadas de Ciencias Computacionales
Inteligencia Artificial
(TC3002B.M2)

José Carlos Ortiz Bayliss



Clasificador Bayesiano ingenuo

- Es un clasificador probabilístico basado en el teorema de Bayes.
- Se le llama "ingenuo" porque asume independencia condicional entre las variables independientes; algo que casi nunca es cierto en la práctica.
- Se utiliza para clasificación, preferentemente con variables independientes categóricas, aunque también trabaja con variables cuantitativas (con distribución normal).

El teorema de Bayes

- El teorema de Bayes es un principio de probabilidad que describe cómo actualizar las creencias sobre un evento basándose en nueva información.
- El teorema establece que la probabilidad $P(A|B)$, se puede calcular a partir de $P(B|A)$ y las probabilidades *a priori* $P(A)$ y $P(B)$ y la evidencia.

El teorema de Bayes

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)} \propto P(Y) \prod_{i=1}^k P(X_i|Y)$$

Donde:

- $P(Y|X)$ es la probabilidad de que Y ocurra si X ocurre (*a posteriori*).
- $P(X|Y)$ es la probabilidad de que X ocurra si Y ocurre.
- $P(Y)$ es la probabilidad inicial de que Y ocurra (*a priori*).
- $P(X)$ es la probabilidad total de X .

¿Podemos salir a jugar golf?

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

El clasificador bayesiano ingenuo en acción

Supongamos que queremos saber si, ante las siguientes condiciones podremos salir a jugar:

Outlook	Temperature	Humidity	Windy	Play
rainy	hot	high	yes	?

$$\begin{aligned}P(\text{Play} = \text{yes} | X) &\propto \\ &P(\text{Play} = \text{yes}) \times \\ &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\ &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\ &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\ &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})\end{aligned}$$

$$\begin{aligned}P(\text{Play} = \text{no} | X) &\propto \\ &P(\text{Play} = \text{no}) \times \\ &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{no}) \times \\ &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{no}) \times \\ &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{no}) \times \\ &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{no})\end{aligned}$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$P(\text{Play} = \text{yes} \mid X) \propto$$

$$P(\text{Play} = \text{yes}) \times$$

$$P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times$$

$$P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times$$

$$P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times$$

$$P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &P(\text{Play} = \text{yes}) \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &0.6429 \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &P(\text{Play} = \text{yes}) \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &0.6429 \times \\
 &0.3333 \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &P(\text{Play} = \text{yes}) \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &0.6429 \times \\
 &0.3333 \times \\
 &0.2222 \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &P(\text{Play} = \text{yes}) \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &0.6429 \times \\
 &0.3333 \times \\
 &0.2222 \times \\
 &0.3333 \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &P(\text{Play} = \text{yes}) \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &0.6429 \times \\
 &0.3333 \times \\
 &0.2222 \times \\
 &0.3333 \times \\
 &0.3333 = 0.0053
 \end{aligned}$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &P(\text{Play} = \text{yes}) \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{yes} \mid X) &\propto \\
 &0.6426 \times \\
 &0.3333 \times \\
 &0.2222 \times \\
 &0.3333 \times \\
 &0.3333 = 0.0053
 \end{aligned}$$

El clasificador bayesiano ingenuo en acción

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{no} \mid X) &\propto \\
 &P(\text{Play} = \text{no}) \times \\
 &P(\text{Outlook} = \text{rainy} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{no})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{no} \mid X) &\propto \\
 &0.3571 \times \\
 &0.4000 \times \\
 &0.4000 \times \\
 &0.8000 \times \\
 &0.6000 = 0.0274
 \end{aligned}$$

El clasificador bayesiano ingenuo en acción

Los valores obtenidos no son probabilidades, son proporciones.

$$P(\text{Play} = \text{yes}|X) = 0.0053$$

$$P(\text{Play} = \text{no}|X) = 0.0274$$

Para convertirlos en probabilidades, debemos dividirlos por $P(X)$.

$$P(X) = P(\text{Play} = \text{yes}|X) + P(\text{Play} = \text{no}|X)$$

De esta manera:

$$P(\text{Play} = \text{yes}|X) = \frac{0.0053}{0.0053 + 0.0274} = 0.1621$$

$$P(\text{Play} = \text{no}|X) = \frac{0.0274}{0.0053 + 0.0274} = 0.8379$$

El efecto de una probabilidad cero

Debido a que el clasificador Bayesiano ingenuo multiplica todas las probabilidades de las características para obtener el resultado final, un valor de cero es suficiente para hacer que toda la probabilidad final sea cero.

Analicemos el siguiente caso:

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	yes	?

El efecto de la probabilidad cero

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$P(\text{Play} = \text{yes} \mid X) \propto$$

$$P(\text{Play} = \text{yes}) \times$$

$$P(\text{Outlook} = \text{overcast} \mid \text{Play} = \text{yes}) \times$$

$$P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times$$

$$P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times$$

$$P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})$$

$$P(\text{Play} = \text{yes} \mid X) \propto$$

$$0.6429 \times$$

$$0.4444 \times$$

$$0.2222 \times$$

$$0.3333 \times$$

$$0.3333 = 0.0071$$

El efecto de la probabilidad cero

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{no} \mid X) &\propto \\
 &P(\text{Play} = \text{no}) \times \\
 &P(\text{Outlook} = \text{overcast} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{no})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{no} \mid X) &\propto \\
 &0.3571 \times \\
 &0.0000 \times \\
 &0.4000 \times \\
 &0.8000 \times \\
 &0.6666 = 0.0000
 \end{aligned}$$

Suavizado de Laplace

- Es una técnica esencial para evitar que el clasificador se "rompa" cuando se encuentra con datos que no vio durante el entrenamiento.
- El suavizado de Laplace añade un pequeño número (típicamente 1) al conteo de cada característica, asegurando que ninguna probabilidad sea exactamente cero.
- Para fines prácticos, el suavizado de Laplace actúa como un mecanismo de regularización, lo que evita que el modelo se ajuste demasiado a las frecuencias exactas del conjunto de entrenamiento.

Suavizado de Laplace

Se modifica el cálculo de las probabilidades:

$$P(X_i|Y_i) = \frac{\text{count}(X_i, Y_i) + \alpha}{\text{count}(Y_i) + \alpha \cdot d}$$

donde:

- α es el parámetro de suavizado (generalmente es 1).
- d es el número de categorías en X_i .

El efecto de la probabilidad cero

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 &P(\text{Play} = \text{yes} \mid X) \propto \\
 &P(\text{Play} = \text{yes}) \times \\
 &P(\text{Outlook} = \text{overcast} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{yes}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{yes})
 \end{aligned}$$

$$\begin{aligned}
 &P(\text{Play} = \text{yes} \mid X) \propto \\
 &0.6429 \times \\
 &0.4167 \times \\
 &0.2500 \times \\
 &0.3636 \times \\
 &0.3636 \times = 0.0089
 \end{aligned}$$

El efecto de la probabilidad cero

Outlook	Temperature	Humidity	Windy	Play
overcast	hot	high	no	yes
overcast	cool	normal	yes	yes
overcast	mild	high	yes	yes
overcast	hot	normal	no	yes
rainy	mild	high	no	yes
rainy	cool	normal	no	yes
rainy	cool	normal	yes	no
rainy	mild	normal	no	yes
rainy	mild	high	yes	no
sunny	hot	high	no	no
sunny	hot	high	yes	no
sunny	mild	high	no	no
sunny	cool	normal	no	yes
sunny	mild	normal	yes	yes

$$\begin{aligned}
 P(\text{Play} = \text{no} \mid X) &\propto \\
 &P(\text{Play} = \text{no}) \times \\
 &P(\text{Outlook} = \text{overcast} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Temperature} = \text{hot} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Humidity} = \text{high} \mid \text{Play} = \text{no}) \times \\
 &P(\text{Windy} = \text{yes} \mid \text{Play} = \text{no})
 \end{aligned}$$

$$\begin{aligned}
 P(\text{Play} = \text{no} \mid X) &\propto \\
 &0.3571 \times \\
 &0.1250 \times \\
 &0.3750 \times \\
 &0.7143 \times \\
 &0.5714 \times = 0.0068
 \end{aligned}$$

Clasificación mediante Bayes ingenuo (variables categóricas)

```
# Importamos los módulos necesarios
import numpy as np
from sklearn.preprocessing import OrdinalEncoder
from sklearn.naive_bayes import CategoricalNB
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix

# Leemos los datos que usaremos
weather = pd.read_csv("weather.csv")

# Separamos las variables independientes de la dependiente
X = weather.drop("Play", axis = 1)
y = weather["Play"]
```

Clasificación mediante Bayes ingenuo (variables categóricas)

```
# Convertimos las variables categóricas a numéricas discretas
encoder = OrdinalEncoder()
X = encoder.fit_transform(X)

# Creamos un modelo de clasificación usando bayes ingenuo
model = CategoricalNB()

# Entrenamos el modelo usando todos los datos disponibles
# No recomendado, se hace con fines académicos
model.fit(X, y)


# Realizamos la predicción usando todos los datos disponibles
# No recomendado, se hace con fines académicos
prediction = model.predict(X)

# Generamos la matriz de confusión
confusion_matrix(y, prediction)
```


Evaluación del desempeño

		Predicción	
		no	yes
Realidad	no	4	1
	yes	0	9

El impacto de la normalidad de los datos



Clasificación mediante Bayes ingenuo (variables numéricas)

```
# Importamos los módulos necesarios
import pandas as pd
from sklearn.naive_bayes import GaussianNB
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix

# Leemos los datos que usaremos
data = pd.read_csv("extreme.csv")

# Separamos las variables independientes de la dependiente
X = data.drop("Class", axis = 1)
y = data["Class"]

# Dividimos los datos en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, train_size = 0.60, stratify = y,
                                                    random_state = 500)
```

Clasificación mediante Bayes ingenuo (variables numéricas)

```
# Creamos un modelo de clasificación usando bayes ingenuo
model = GaussianNB()



# Entrenamos el modelo usando los datos de entrenamiento
model.fit(X_train, y_train)

# Realizamos la predicción usando los datos de prueba
prediction = model.predict(X_test)



# Generamos la matriz de confusión
confusion_matrix(y_test, prediction)
```

Evaluación del desempeño

		Predicción	
		high	low
Realidad	high	140	260
	low	0	400



El impacto de la normalidad de los datos



Clasificación mediante Bayes ingenuo (variables numéricas)

```
# Importamos los módulos necesarios
import pandas as pd
from sklearn.naive_bayes import GaussianNB
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix

# Leemos los datos que usaremos
data = pd.read_csv("extreme.csv")

# Separamos las variables independientes de la dependiente
X = data.drop("Class", axis = 1)
y = data["Class"]

# Tratamos de cumplir la normalidad de los datos mediante una transformación logarítmica
X = np.log(X)
```

Clasificación mediante Bayes ingenuo (variables numéricas)

```
# Dividimos los datos en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, train_size = 0.60, stratify = y,
    random_state = 500)

# Creamos un modelo de clasificación usando bayes ingenuo
model = GaussianNB()



# Entrenamos el modelo usando los datos de entrenamiento
model.fit(X_train, y_train)

# Realizamos la predicción usando los datos de prueba
prediction = model.predict(X_test)

# Generamos la matriz de confusión
confusion_matrix(y_test, prediction)
```


Evaluación del desempeño


		Predicción	
		high	low
Realidad	high	400	0
	low	0	400




Normalización de los datos

Además del logaritmo, existen otras funciones que pueden ayudar a normalizar los datos.


$$\sqrt{x}$$



$$\sqrt[3]{x}$$



$$\frac{1}{x}$$



Conclusiones

- Los modelos resultantes son simples de implementar y rápidos para entrenar. De hecho, se encuentra entre los algoritmos más rápidos.
- En la mayoría de los casos, sus decisiones son fáciles de entender (aunque requiere interpretar probabilidades condicionales).
- Funciona muy bien, incluso cuando el número de variables independientes se incrementa drásticamente.
- El proceso no requiere normalizar los datos, pero las variables cuantitativas deben seguir una distribución de probabilidad normal.